

# САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

Математико-Механический факультет

Кафедра гидроаэромеханики

## Применение моделей машинного обучения в задачах гидроаэродинамики

Отчёт по работе студентов 151 и 153 группы

Шмидта Д., Жабиной М., Сметаниной Е., Абдрашитовой А., Казакова В.

Научный руководитель: Исаков А.

Санкт-Петербург  
2023 г.

# Содержание

|     |                                    |    |
|-----|------------------------------------|----|
| 1   | Введение                           | 2  |
| 2   | Постановка задач                   | 2  |
| 3   | Модели машинного обучения          | 4  |
| 3.1 | kNN: k-Nearest Neighbors . . . . . | 5  |
| 3.2 | DT: Decision Tree . . . . .        | 5  |
| 3.3 | Non-linear regression . . . . .    | 6  |
| 3.4 | DeepXDE . . . . .                  | 7  |
| 4   | Результаты                         | 7  |
| 5   | Заключение                         | 11 |

# 1 Введение

В последние десятилетия модели машинного обучения привлекают все больше внимания в контексте их применения в задачах гидроаэродинамики. С возросшей доступностью данных и вычислительных мощностей эти методы стали эффективным инструментом для прогнозирования и анализа потоков жидкостей и газов, что имеет важное значение при решении множества инженерных и научных задач.

Целью данной работы является изучение возможностей моделей машинного обучения в задачах гидроаэродинамики, их преимуществ и ограничений. Нами были рассмотрены как классические методы машинного обучения: k-Nearest Neighbors, Decision Tree, так и более специфичные: нелинейная регрессия и физически-информированная нейронная сеть из библиотеки DeepXDE. Также были рассмотрены конкретные приложения этих методов в задачах гидроаэродинамики. Для этого были задействованы наборы данных, сгенерированные на основе точных решений плоских задач Пуазейля и Куэтта в условиях ламинарного течения. Эти задачи являются эталонами, поскольку они имеют аналитические решения, которые могут быть использованы для сопоставления с результатами, полученными при помощи моделей машинного обучения, и оценки их точности. Для валидации рассмотренных моделей также были использованы данные, полученные в ходе эксперимента [2, 3]. Это важное дополнение, поскольку экспериментальные данные отражают реальное поведение жидкости в условиях, наиболее приближенных к реальным гидродинамическим процессам.

## 2 Постановка задач

Уравнения, используемые для описания потока:

Уравнение несжимаемости:

$$\frac{\partial V_x}{\partial x} + \frac{\partial V_y}{\partial y} + \frac{\partial V_z}{\partial z} = 0 \quad (1)$$

Уравнение Навье-Стокса:

$$\rho \left( \frac{\partial \bar{v}}{\partial t} + (\bar{v} \cdot \nabla) \bar{v} \right) = -\nabla p + \eta \Delta \bar{v} + \bar{f}_g \quad (2)$$

где  $\rho$  – плотность,  $\eta$  – коэффициент динамической вязкости,  $t$  – время,  $p$  – давление,  $\bar{v}$  – векторное поле скорости,  $\bar{f}_g$  – векторное поле массовых сил,  $V_i$  – проекции скоростей на оси координат,  $i = x, y, z$ .

Плоское течение Куэтта: Рассмотрим пространство, образованное двумя параллельными плоскими твердыми стенками. Будем считать, что размеры стенок бесконечны. Пространство между пластинами заполнено

вязкой жидкостью, которая движется ламинарно; стенки для нее непроницаемы, расстояние между ними равно  $h$ . Предположим, что нижняя стенка неподвижна, а верхняя перемещается в своей плоскости с постоянной скоростью  $U$ . Требуется найти стационарное распределение скорости внутри потока. Введем декартову систему координат с началом на нижней плоскости, осью  $x$ , направленной вдоль скорости движения верхней плоскости, и осью  $y$ , направленной вертикально вверх. Из соображений симметрии задачи следует, что  $z$ -компонента скорости  $\bar{v}$  равна нулю, так как оба направления движения вдоль этой оси равноправны и система не может выбрать ни одно из них. Из этих же соображений следует, что от координаты  $y$  оставшиеся компоненты скорости и давление зависят не могут. Таким образом, задача из трехмерной становится двумерной. В этой постановке уравнение Навье-Стокса (2) выглядит так:

$$\rho \left( V_x \frac{\partial}{\partial x} + V_y \frac{\partial}{\partial y} \right) V_x = -\frac{\partial p}{\partial x} + \eta \left( \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} \right) V_x \quad (3)$$

$$\rho \left( V_x \frac{\partial}{\partial x} + V_y \frac{\partial}{\partial y} \right) V_y = -\frac{\partial p}{\partial y} + \eta \left( \frac{\partial^2}{\partial x^2} + \frac{\partial^2}{\partial y^2} \right) V_y \quad (4)$$

Уравнение несжимаемости(2) сейчас имеет вид:

$$\frac{\partial V_x}{\partial x} + \frac{\partial V_y}{\partial y} = 0 \quad (5)$$

Учтем теперь, что все точки в направлении оси  $x$  физически равноправны, а выбор начала координат в нижней плоскости совершенно произволен. Физические результаты не могут зависеть от произвола при выборе начала координат, поэтому от координаты  $x$  ни компоненты скорости  $\bar{v}$ , ни давление  $p$  зависеть не могут. Следовательно, вместо (5) имеем  $\frac{\partial V_y}{\partial y} = 0$ , значит  $V_y = \text{const}$  и в силу непроницаемости стенок,  $V_y = 0$ . С учетом равенства нулю  $v$  и производных по  $x$  уравнения (3)-(4) сводятся к уравнению:

$$\frac{\partial^2 V_x}{\partial y^2} = 0 \quad (6)$$

Решение которого:

$$V_x = Ax + B, \quad (7)$$

где  $A$  и  $B$  – постоянные интегрирования. Из условия прилипания на нижней границе следует, что  $V_x = 0$  при  $y = 0$ . Следовательно,  $B = 0$ . На верхней границе в силу этого же условия скорость жидкости равна скорости верхней стенки, т. е.  $V_x = U$  при  $y = h$ . Поэтому  $A = \frac{U}{h}$ . Таким образом,

$$V_x = U \frac{y}{h} \quad (8)$$




Рис. 1: Профиль распределения скорости в плоской задаче Куэтта

Плоское течение Пуазейля: Снова рассмотрим пространство, образованное двумя параллельными плоскими твердыми стенками. Будем считать, что размеры стенок бесконечны. Пространство между пластинами заполнено вязкой жидкостью, которая движется ламинарно; стенки для нее непроницаемы, ширина равна  $h$ . Жидкость приводится в движение постоянным градиентом давления  $G = -\frac{\partial p}{\partial x}$ . Тогда уравнение Навье-Стокса сводится к:

$$\frac{\partial^2 V_x}{\partial y^2} = -\frac{G}{\eta} \quad (9)$$

Учитывая, что в  $y = 0$  и  $y = h$ ;  $V_x = 0$ , получим уравнение:

$$V_x = \frac{G}{2\mu} y(h - y) \quad (10)$$




Рис. 2: Профиль распределения скорости в плоской задаче Пуазейля

### 3 Модели машинного обучения

Для нахождения профиля скорости для описанных ранее задач будем использовать различные модели машинного обучения.

### 3.1 kNN: k-Nearest Neighbors

Модель kNN основана на гипотезе компактности – схожие объекты чаще лежат в одном классе, чем в разных, т.е. значение нового объекта определяется из значений k ближайших к нему «соседей».

Для поиска ближайшего соседа используют различные варианты метрик:

- Евклидово расстояние:

$$D_{Eucl} = \sqrt{\sum_{i=1}^N (x_i - y_i)^2} \quad (11)$$

- Манхэттенское расстояние:

$$D_{Manh} = \sum_{i=1}^k |x_i - y_i| \quad (12)$$

- Метрика Минковского:

$$D_{Mink} = \left( \sum_{i=1}^k |x_i - y_i|^q \right)^{\frac{1}{q}} \quad (13)$$

Данные формулы помогают нам найти расстояния до ближайших «соседей» и спрогнозировать будущее значение нового элемента. Новый элемент получает значение, как среднее значение этих «соседей».

Так же немаловажно упомянуть о нормализации. Так как разные атрибуты могут иметь разный диапазон, то значения дистанции могут сильно зависеть от диапазона рассматриваемых значений. Для того, чтобы это учесть существует 2 вида нормализации

Minmax нормализация:

$$x' = \frac{x - X_{min}}{X_{max} - X_{min}} \quad (14)$$

в этом случае все значения будут лежать в диапазоне от 0 до 1.

Z-нормализация:

$$x' = \frac{x - \bar{x}}{\sigma[X]}, \quad (15)$$

где  $\bar{x}$  - среднее значение атрибута;  $\sigma$  — среднеквадратичное отклонение.

### 3.2 DT: Decision Tree

Непараметрический метод обучения с учителем - Дерево решений используется для решения задач классификации и регрессии. На основании тренировочной данных (учителя) строится дерево.

В этой структуре в каждой вершине, не являющейся листом, происходит проверка аргументов на соответствие с правилом. Правила формируются при обучении модели (от корня к листьям), таким образом, что в каждом узле происходит оптимальное разделение данных.

Оценка разделение данных в деревьях решений часто происходит по теоретико-информационному критерию (выбирается максимальный) или по индексу Джини (выбирается минимальный).

Теоретико-информационные критерий:

$$Grain(X) = Info(T) - Info_X(T) \quad (16)$$

$$Info(T) = \sum_i^N -p_i \log_2 p_i \quad (17)$$

$$Info_X(T) = \sum_i^N \frac{|T_i|}{|T|} Info(T_i) \quad (18)$$

Индекс Джини:

$$Gini(X) = 1 - \sum_i^N p_i^2, \quad (19)$$

где  $X$  - проверка в узле;  $T$  - исходное множество;  $T_i$  - разбиения исходного множества;  $N$  - количество классов разбиения;  $p_i$  - частотная вероятность

Алгоритм построения этой структуры является жадным. Считаем, что оптимальное разделение в каждой вершине приводит к лучшему общему решению.

### 3.3 Non-linear regression

Для расчета профилей скорости было предложено использовать аппроксимационные формулы, полученные с помощью нелинейной регрессии точных значений. Рассмотрим аппроксимацию для скорости  $v^*$  в следующем виде:

$$v^*(y) = A \cdot y^2 + B \cdot y + C, \quad (20)$$

где  $A, B, C$  - коэффициенты, получаемые с помощью нелинейной регрессии.

Для нахождения коэффициентов  $A, B$  и  $C$  используется регрессия по значениям скоростей, вычисленным с помощью точных аналитических решений:

$$v(y_i) = A \cdot y_i^2 + B \cdot y_i + C + \varepsilon_i, \quad (21)$$

где  $\varepsilon_i$  — регрессионный остаток.

Обозначим полный вектор искомых параметров регрессионной модели, как  $Y = (A, B, C)$ . Тогда задача определения набора параметров  $Y^*$ ,

дающего наилучшее приближение, может быть записана в экстремальной форме:

$$\Upsilon^* = \operatorname{argmin}_{\Upsilon} \mathbf{D}(v_i, v_i^*), \quad (22)$$

где  $\mathbf{D}$  — некоторая метрика, вычисляемая для сравнения аппроксимированных и точных значений.

### 3.4 DeepXDE

Deep Learning добилось замечательных успехов в различных прикладных сферах. В библиотеке DeepXDE [1] представлены нейронные сети с учетом физики (PINN-Physics-informed neural network). Алгоритм PINN может применяться к различным типам уравнений. В частности, DeepXDE может решать прямые задачи с учетом начальных и граничных условий, а также обратные задачи с учетом некоторых дополнительных измерений.

Данная библиотека использует два основных алгоритма:

1. Глубокие нейронные сети. Математически глубокая нейронная сеть - это конкретный выбор композиционной функции. Простейшей нейронной сетью является нейронная сеть с прямой связью (FNN), также называемая многослойным персептроном (MLP), которая рекурсивно применяет линейные и нелинейные преобразования к входным данным.
2. Алгоритмическое дифференцирование. Существует четыре возможных метода вычисления производных:
  - (a) аналитический производный с ручным кодированием;
  - (b) конечная разность или другие численные приближения;
  - (c) символьное дифференцирование (используется в таких программах, как Mathematica, Maxima и Maple);
  - (d) алгоритмическое (автоматическое) (именно оно и применяется в пакете)

## 4 Результаты

Для обучения исследуемых моделей машинного обучения была написана программа генерирующая данные на основе точных решений плоских задач Пуазейля и Куэтта. Для обработки и хранения полученных данных использовалась библиотека Pandas на языке Python. Так же были получены экспериментальные значения, которые так же использовались при оценке точности предсказания моделей машинного обучения






Рис. 3: Сгенерированные данные для задачи Куэтта (слева), задачи Пуазейля (справа) и экспериментальных данных [2, 3]

kNN: При работе с моделями машинного обучения одной из основных задач является подбор гиперпараметров для улучшения результатов работы рассматриваемой модели. Для kNN - это определение оптимального количества соседей, которое будет давать наиболее точные предсказания. В данном исследовании, по результатам тестов программы с разными значениями  $k = 2, 3, 4, 5$ ; было выбрано  $k = 3$ , как дающее наибольшую точность.

На рис. (4) представлены результаты обучения модели kNN для задач Пуазейля и Куэтта. Полученные результаты хорошо согласуются с исходными данными для обеих задач. По данным графикам видно, что наиболее точные значения модель выдает в верхней части гиперболы, где расстояние между ближайшими соседями меньше, в то время как, чем дальше по ветвям параболы мы уходим, тем менее точное значение получаем.




Рис. 4: Результаты предсказаний kNN и экспериментальные значения для плоского течения Куэтта(слева) и плоского течения Пуазейля(справа)

DT: В данной работе для построения дерева используется библиотека scikit-learn, в которой реализована оптимизированная версия алгоритма

CART. Алгоритм CART строит бинарное дерево решений и использует индекс Джини для выбора правил разделения.

В ходе исследования было получено, что оптимальной глубиной дерева решений, построенного на основании данных для плоского течения Куэтта - 7, для плоского течения Пуазейля - 18.




Рис. 5: Результаты предсказаний дерева решений и экспериментальные значения для плоского течения Куэтта (слева) и плоского течения Пуазейля (справа)

Non-lin. regression: Для нахождения  $Y^*$  использовался метод оптимизации Левенберга–Марквардта, реализованный в библиотеке `scipy` на языке Python (<https://scipy.org>). Этот метод является классическим подходом, применяющимся для решения задачи нелинейной регрессии.

В ходе исследования были получены следующие аппроксимации для задачи Куэтта и задачи Пуазейля, соответственно:

$$v_{cuet} = 1.73e-9 \cdot y^2 + 0.29 \cdot y + 4.74e-12 \quad (23)$$

$$v_{pois} = -6601.02 \cdot y^2 + 92.41 \cdot y + 5.43e-8 \quad (24)$$

DeepXDE: При решении данных задач была использована нейронная сеть прямого распространения (`maps.FNN`), т.е. сеть в которой сигнал распространяется строго от входного слоя к выходному. Данная нейронная сеть является многослойной, т.е. состоит из входного, выходного и расположенных между ними скрытых слоев нейронов (см. рис.7).

Таким образом решение задачи сводится к поиску оптимального количества скрытых слоев нейронов.

Для решения задачи Куэтта оптимальным соотношением стало  $[1]+[3]+[1]$ , а для Пуазейля  $[1]+[5]+[1]$ . При этом увеличение ни количества промежуточных нейронов, ни их слоев не повышало точности нейросети.

Для оценки качества исследуемых моделей были использованы следующие метрики:

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \bar{y}_i)^2 \quad (25)$$




Рис. 6: Результаты предсказаний нелинейной регрессии и экспериментальные значения для плоского течения Куэтта (слева) и плоского течения Пуазейля (справа)




Рис. 7: Схематичное строение многослойной нейронной сети




Рис. 8: Визуализация данных результатов прогнозирования построенных на основе библиотеки deepXDE для течения Куэтта (слева) и Пуазейля (справа)

$$MSE = \frac{1}{N} \sum_{i=1}^N |y_i - \bar{y}_i| \quad (26)$$

Таблица 1: Значения метрик MSE и MAE для течения Пуазейля

| Метрика        | MSE        |                     |                     | MAE        |                     |               |
|----------------|------------|---------------------|---------------------|------------|---------------------|---------------|
| Выборка        | train      | test                | experiment          | train      | test                | experiment    |
| Модель         |            |                     |                     |            |                     |               |
| kNN            | 0.0        | 2.4469e-06          | 0.0008              | 0.0        | 0.0003              | 0.0132        |
| DT             | 0.0        | 4.7664e-05          | 0.0004              | 0.0        | 0.0061              | 0.0136        |
| Non-lin. regr. | 9.2420e-14 | <b>8.2684e – 14</b> | 0.0003              | 2.6719e-07 | <b>2.4564e – 07</b> | 0.0115        |
| deepXDE        | 0.0001     | 0.0001              | <b>1.0613e – 04</b> | 0.0098     | 0.0088              | <b>0.0083</b> |

Таблица 2: Значения метрик MSE и MAE для течения Куэтта

| Метрика        | MSE        |                     |                     | MAE        |                     |               |
|----------------|------------|---------------------|---------------------|------------|---------------------|---------------|
| Выборка        | train      | test                | experiment          | train      | test                | experiment    |
| Модель         |            |                     |                     |            |                     |               |
| kNN            | 0.0        | 9.5389e-08          | 0.0003              | 0.0        | 5.3045e-07          | 0.0006        |
| DT             | 0.0        | 2.8503e-07          | 4.7799e-07          | 0.0        | 0.0005              | 0.0005        |
| Non-lin. regr. | 1.8488e-20 | <b>2.1088e – 20</b> | 4.7035e-07          | 1.1668e-10 | <b>1.2971e – 10</b> | <b>0.0004</b> |
| deepXDE        | 1.0449e-07 | 2.9169e-07          | <b>2.9200e – 07</b> | 0.0003     | 0.0005              | 0.0005        |

Из табл. (1) видно, что лучше всего с описанием тестовой выборки для задачи Пуазейля справляется модель нелинейной регрессии. Лучше всего описывает экспериментальные данные нейронная сеть из библиотеки DeepXDE.

Из табл. (2) видно, что лучше всего с описанием данных для задачи Куэтта справляется модель нелинейной регрессии.

## 5 Заключение

В ходе работы было произведено сравнение нескольких моделей машинного обучения: kNN, DT, Non-lin. regr. и нейронная сеть из библиотеки DeepXDE. Каждая модель была применена для аппроксимации профилей скорости для задач Куэтта и Пуазейля. Для обеих задач посчитаны метрики MSE и MAE на тестовом и экспериментальном наборе данных. По получившимся значениям метрик можно сделать вывод, что модель нелинейной регрессии справляется с прогнозированием данных лучше остальных моделей, но уступает нейронной сети при описании данных, которые были получены из экспериментов.

## Список литературы

- [1] Lu Lu, Xuhui Meng, Zhiping Mao and George Em Karniadakis DeepXDE: A Deep Learning Library for Solving Differential Equations—SIAM Review Volume 63, Issue 1, 2021
- [2] Reichardt H. Gesetzmässigkeiten der geradlinigen turbulenten Couette-Strömung Mitt. № 22 des Max-Planck-Inst. für Strömungsforschung und der AVA Göttingen (1959).

- [3] Tomoya Watanabe, Haruo Isoda, Atushi Fukuyama, Mamoru Takahashi, Tomoyasu Amano, Yasuo Takehara, Naoki Oishi, Masanori Kawate, Masaki Terada, Takafumi Kosugi, Yoshiaki Komori, Yukiko Fukuma, Marcus Alley Accuracy of the Flow Velocity and Three-directional Velocity Profile Measured with Three-dimensional Cine Phase-contrast MR Imaging: Verification on Scanners from Different Manufacturers, March 4, 2019